Instituto Tecnológico y de Estudios Superiores Monterrey Inteligencia Artificial para la Ciencia de Datos



Entrega 1: Exploración y Formulación de Hipótesis

Equipo 4

Esteban Sierra Baccio | A00836286

Diego Esparza Ruíz | A00837527

Javier Jorge Hernández Verduzco | A01722667

Sergio Omar Flores García | A01285193

Sergio Aarón Hernández Orta | A01613878

17 de agosto del 2025

Resumen Ejecutivo	3
Hallazgos clave del Análisis exploratorio de datos	3
Hipótesis principales propuestas	3
Introducción4	1
Objetivos del análisis4	1
Estructura del reporte	1
Análisis Exploratorio de Datos	5
Descripción del dataset	5
Hallazgos principales con visualizaciones clave	5
Patrones y anomalías identificadas10)
Contextualización Histórica1	1
Conexión Datos-Historia	2
Hipótesis de Investigación14	1
Hipótesis #1: La posibilidad de supervivencia aumenta en cuestión de tener hijos menores a bordo14	4
Hipótesis #2: La probabilidad de supervivencia en primera clase es al menos 50% mejor que la de tercera clase, para todas las edades y géneros14	,
Hipótesis #3: La posibilidad de supervivencia disminuye en cuestión de ser de tercera vinculados a varios familiares provenientes de Southampton1	5
Hipótesis secundaria #1: En tercera clase sólo existía una opción de cuarto16	3
Conclusiones Preliminares17	7
Resumen de insights17	7
Próximos pasos17	7
Referencias18	3

Resumen Ejecutivo

En este reporte analizamos una muestra de un dataset con información de los pasajeros en el RMS Titanic durante el viaje en el que se hundió, y exploramos las variables que nos permiten modelar o medir aquello que definió el destino de los más de 2000 pasajeros a bordo.

Respondemos múltiples hipótesis que abordan teorías sobre las situaciones y circunstancias que atenuaron o agravaron la situación para aquellos a bordo al momento del hundimiento del barco, empezando por un análisis detenido de los datos en nuestras manos, las relaciones y proporcionas más obvias y en la superficie, y continuamos formulando nuestras hipótesis y explorando el contexto histórico y cultural durante el tiempo que el Titanic navegó, y la situación de las personas a bordo. Finalmente, utilizando las visualizaciones básicas y creando nuevas para la comparación de situaciones más complejas y específicas, respondemos una por una nuestras hipótesis y descubrimos patrones y anomalías nuevas.

Finalmente, compartimos nuestros hallazgos e *insights* y las preguntas que quedaron al haber experimentado repetidamente con este dataset.

Hallazgos clave del Análisis exploratorio de datos

- 1. La tasa de supervivencia aumenta en base a la clase en la que se encontraba el pasajero.
- 2. Hay evidencia que soporta que se le dio prioridad a las mujeres y niños de todas las clases.
- 3. Hay evidencia que permite relacionar el número de padres/hijos con la supervivencia de las familias.

Hipótesis principales propuestas

Hipótesis #1: Los pasajeros con hijos menores de edad tuvieron mayor probabilidad de supervivencia que los pasajeros sin hijos menores de edad.

Hipótesis #2: La probabilidad de supervivencia en primera clase es al menos 50% mejor que la de tercera clase, para todas las edades y géneros.

Hipótesis #3: La posibilidad de supervivencia disminuye en cuestión de ser de tercera vinculados a varios familiares provenientes de Southampton

Introducción

Objetivos del análisis

El análisis sobre los pasajeros del accidente del Titanic en 1912 permite descubrir la causalidad probabilística que tenían cada uno de los pasajeros de sobrevivir, esta información puede ser utilizada con fines tanto educativos como de seguridad y protección para casos parecidos al del incidente investigado. El análisis permitirá encontrar relaciones entre distintos datos que determinarán la supervivencia de los pasajeros y la búsqueda de soluciones que permitan la supervivencia de la mayor cantidad de personas posibles.

Estructura del reporte

Este reporte integra análisis cuantitativos con contextualización histórica mediante una progresión lógica estructurada. Inicia con un **análisis exploratorio** que caracteriza el dataset e identifica patrones emergentes, estableciendo la base empírica para hipótesis posteriores. La **contextualización histórica** sitúa los hallazgos estadísticos dentro de las estructuras sociales eduardianas, explicando los mecanismos causales subyacentes. La sección de **hipótesis** formaliza proposiciones comprobables con metodologías de validación específicas. Finalmente, las **conclusiones preliminares** sintetizan insights y establecen la agenda para investigaciones futuras, asegurando que los resultados estén fundamentados tanto en evidencia cuantitativa como en comprensión histórica.

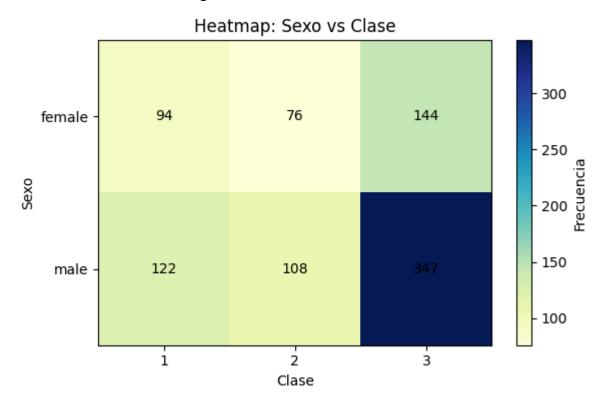
Análisis Exploratorio de Datos

Descripción del dataset

El dataset utilizado para el análisis exploratorio de datos tiene hace uso de 12 dimensiones, desde las cuales podemos obtener datos como el sexo de los pasajeros, su edad, si tenían hermanos, hijos o padres abordo, el precio de su ticket, el lugar donde embarcó, y por supuesto si sobrevivieron o no.

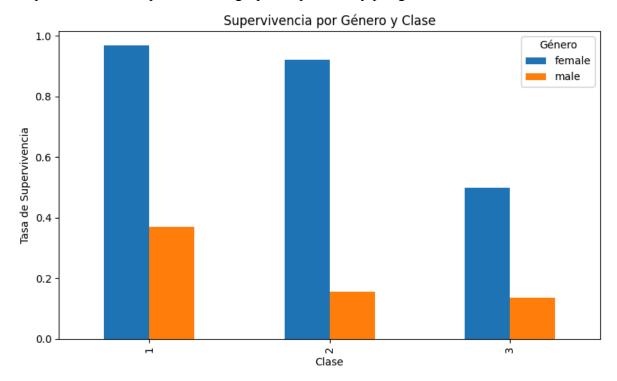
Hallazgos principales con visualizaciones clave

Los primeros hallazgos que se encontraron, siendo los más evidentes, fueron las diferencias de volumen de pasajeros entre las clases. El heatmap creado durante el análisis exploratorio muestra claramente este hallazgo:



Solamente los hombres de tercera clase son más pasajeros que las mujeres de todas las clases juntas, y los 491 hombres y mujeres de la tercera clase son más de la mitad (55%) del volumen de pasajeros total en nuestra muestra. Más adelante, y en varias otras visualizaciones en nuestro notebook, se demostró que el grupo de hombres de tercera clase no solo fue el más numeroso, sino también el grupo con peor tasa de supervivencia.

Como parte del análisis exploratorio de datos, se creó la siguiente gráfica que permite comparar la tasa de supervivencia agrupando por clase y por género:



La tabla con los datos representados en esta gráfica de barras son estos:

	Mujeres	Hombres
1era clase	0.968085	0.368852
2da clase	0.921053	0.157407
3era clase	0.50000	0.135447

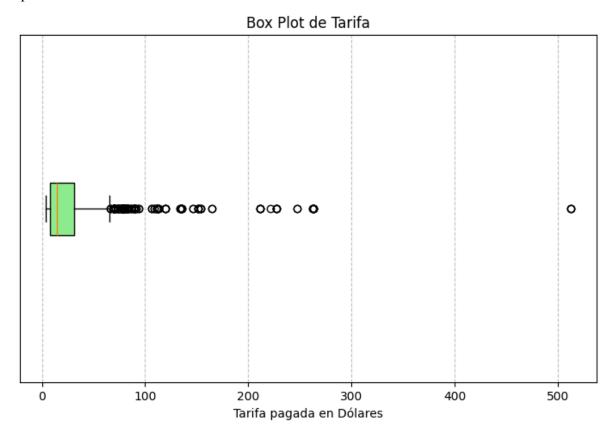
La hipótesis #2 era que manteniendo constante el género, las probabilidades de supervivencia de la primera clase serían 50% mejores que los de tercera clase, con esta tabla se puede verificar esta hipótesis.

Género	% de supervivencia 1era clase	% de supervivencia 3era clase	Diferencia (1ra / 3ra)
Hombres	36.9%	13.5%	173.33%
Mujeres	96.8%	50%	93.60%

En ambos casos, la proporción de las tasas de supervivencia favorecieron a aquellos en primera clase. Casi 2 veces la probabilidad de sobrevivir como una mujer de primera clase comparado a la de tercera, y casi 3 veces la probabilidad de haber sobrevivido como hombre.

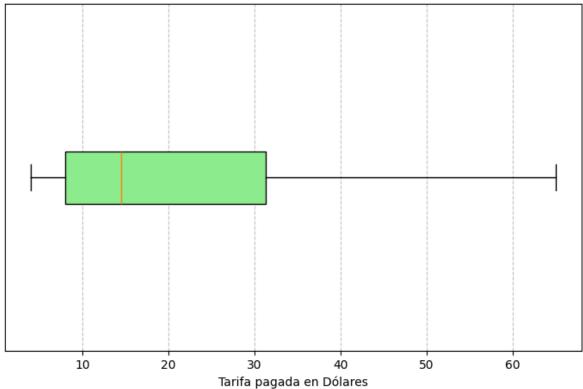
Estos resultados, bajo las condiciones y variables que se habían establecido, prueban correcta la hipótesis #2, y apuntan a una diferencia sistémica, no aleatoria.

Otro hallazgo interesante fue la distribución de las tarifas, estas en un rango desde 4 dólares hasta más de 500 en el caso de una o dos familias. Este rango tan grande pero con tanta varianza crea una boxplot que queda francamente inservible si no se le quitan los valores atípicos:

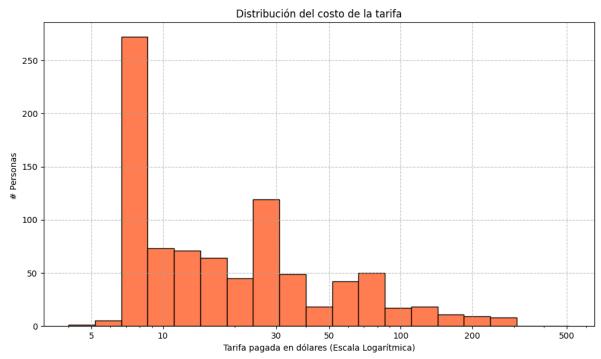


Pero una vez eliminados los valores atípicos, se puede entender mejor el precio "real" o esperado de los boletos al Titanic.





Dicho esto, la mejor representación de las tarifas es en un histograma con el eje horizontal logarítmico, porque así se pueden apreciar y diferenciar las clases entre los precios debajo de 100, y los valores atípicos solo son una minoría sumada en clases enormes.

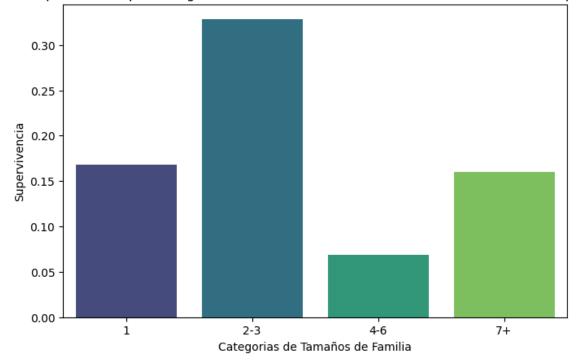


Ahora, referente a la hipótesis #3, se puede observar la cantidad de pasajeros que cumplían con los criterios establecidos por las variables independientes en donde podemos observar como había un alto rango para los pasajeros que solo eran ellos mismos mientras que la cantidad iba bajando drásticamente conforme aumentaba el tamaño de la familia.

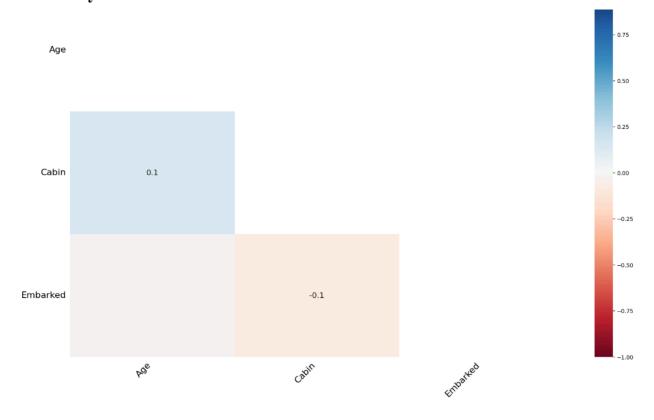
Rangos de Tamaño de Familia/ Subgrupo	Cantidad por Cada Rango de Tamaño dee Familia/Subgrupo
1	232
2-3	67
4-6	29
7+	25

Sin embargo, si contemplamos la tasa de supervivencia de estos pasajeros, se puede observar que los pasajeros que pertenecían a los tamaños de familia de 4, 5 y 6 tenían bajas tasas de supervivencia en comparación a pasajeros que iban solos.





Patrones y anomalías identificadas



Analizando los valores faltantes, observamos que no todos los datos faltantes son aleatorios, ya que su presencia está asociada a otras variables del conjunto. Por ejemplo, la ausencia de la edad es más frecuente en pasajeros de tercera clase, lo que sugiere diferencias en el rigor durante el registro de diferentes clases de pasajeros. Aún más evidente, la información de la cabina falta en la gran mayoría de pasajeros de segunda y tercera clase, pero está presente con mayor frecuencia en primera clase, reafirmando diferencias sistemáticas según la clase del boleto. Estos patrones sugieren que la falta de datos está vinculada a las características del pasajero, y no se distribuye de forma independiente, por lo que consideramos que son sistemáticos.

De manera curiosa y relacionado a una hipótesis secundaria, descubrimos que las tarifas por los boletos tienen correlación con el número de familiares abordando sólo significativamente en la 3era clase, lo que parece indicar que a pesar haber solo 3 clases en nuestro dataset, dentro de las 2da y 1era clases había probablemente más opciones de habitaciones variando en lujo y precio, variables que afectan el precio que no hay en la tercera clase.

Clase	Correlación # familiares → Tarifa
1era clase	0.407
2da clase	0.557
3era clase	0.805

Contextualización Histórica

La sociedad eduardiana y sus estratificaciones sociales

La sociedad eduardiana (1901–1910) se caracterizó por una marcada división entre clases sociales. La aristocracia y la élite financiera gozaban de riqueza, lujos y tiempo libre, mientras que la clase media se expandía con comerciantes, profesionales y funcionarios, y la clase trabajadora sufría condiciones laborales duras, bajos salarios y viviendas precarias.

En la cúspide, las familias ricas vivían en mansiones, viajaban constantemente y mantenían un séquito de sirvientes. Su estilo de vida estaba reflejado en el Titanic: cenas de varios tiempos, salones de baile, bibliotecas y gimnasios. Por contraste, la clase baja eran muchos inmigrantes irlandeses, italianos y escandinavos, se enfrentaba a largas jornadas en fábricas o en el campo, con ingresos mínimos que apenas alcanzaban para subsistir.

Este orden social influiría en la manera en que se organizó la vida a bordo del Titanic y, posteriormente, en quiénes tuvieron más posibilidades de sobrevivir al naufragio.

El diseño del Titanic y distribución de clases

El **RMS** Titanic fue construido por Harland & Wolff en Belfast y operado por la White Star Line, fue considerado el buque más grande y lujoso de su época. El interior del buque estaba pensado para que cada clase social viviera experiencias muy distintas dentro del mismo barco.

Para la primera clase era prácticamente un hotel de lujo flotante, con comedores elegantes, gimnasios, piscina y hasta un café de estilo parisino. La segunda clase, que estaba destinada a profesionales o comerciantes acomodados, gozaba de cabinas confortables y espacios sociales dignos, aunque más sencillos. En comparación, la tercera clase, que eran en su mayoría inmigrantes europeos que buscaban una mejor vida en América, estaba situada en los niveles más bajos del barco, con habitaciones compartidas y acceso limitado a áreas comunes.

Protocolos marítimos de la época

A principios del siglo XX, la navegación transatlántica estaba regulada por normativas marítimas que, vistas en retrospectiva, resultaban insuficientes. Un ejemplo claro fue la escasa cantidad de botes salvavidas exigida, las regulaciones de entonces se basaban en el tamaño del barco y no en la cantidad de pasajeros, por lo tanto, el titanic, con más de 2200 personas a bordo, solo contaba con botes para la mitad de ellas.

Otros protocolos estaban más orientados a la disciplina naval: señales de emergencia, orden jerárquico en la tripulación y rutinas de seguridad. Sin embargo, no existían simulacros ni instrucciones claras para los pasajeros sobre cómo actuar en caso de siniestro, esto explica en gran parte el caos que hubo en la noche del naufragio.

El código "mujeres y niños primero" y su aplicación real

El código de "mujeres y niños primero" proviene de los sucesos ocurridos en el hundimiento del transporte de tropas HMS Birkenhead en donde la mayoría de los soldados se ahogaron

por culpa de los tiburones al momento que los soldados intentaron llegar a la costa más cercana o por culpa de aferrarse a los escombros del barco, sin embargo, la tripulación mantuvo la calma antes de abordar los barcos salvavidas en donde los soldados ayudaron a las mujeres y a los niños a subirse a los barcos (este código sirvió como ejemplo de disciplina suprema, coraje y auto sacrificio).

Demografía de los pasajeros por nacionalidad y propósito del viaje

Hay que recordar que el **RMS Titanic** fue construido en Gran Bretaña, fue operado por súbditos británicos y tripulado por británicos, lo cual explica la preferencia que la tripulación tuvo hacia los pasajeros británicos, que fácilmente fueron identificados por su acento, durante el desastre que sufrió el barco, de forma opuesta, los pasajeros Americanos/Estadounidenses, los pasajeros Irlandeses y, particularmente, los pasajeros escandinavos eran los que tenían una desventaja.

Adicionalmente, el **RMS** Titanic tuvo múltiples propósitos que eran los siguientes:

- 1. Transportar a una numerosa cantidad de personas desde Southampton, Inglaterra hasta Nueva York, Estados Unidos.
- 2. Transportar correo como indican sus siglas RMS (Royal Mail Ship).
- 3. Ofrecer una experiencia de lujo gracias a sus comodidades de alta calidad.

Así mismo, algunos de los mayores propósitos de los pasajeros eran:

- 1. Los pasajeros se subían al barco debido a compromisos laborales o para cerrar tratos comerciales.
- 2. Los pasajeros se subían para experimentar y disfrutar viajes dentro de un barco de alto estatus y lujo.
- 3. Los pasajeros que provenían de otras partes del mundo se subían para buscar nuevas oportunidades en Estados Unidos.

Conexión Datos-Historia

El análisis exploratorio de datos (EDA) confirma las desigualdades sociales ya mencionadas gracias a los registros muestran que mujeres y niños de primera y segunda clase tuvieron una mayor probabilidad de sobrevivir, en contraste con la tercera clase, donde incluso familias enteras desaparecieron. Esto coincide con el contexto histórico: la prioridad se aplicó selectivamente y la ubicación de los camarotes dificultó el acceso a los botes salvavidas. Además, la nacionalidad jugó un papel importante: los pasajeros angloparlantes recibieron instrucciones más claras que otros grupos migrantes, lo que también se refleja en los datos de mortalidad.

Los datos del Titanic muestran cómo las jerarquías sociales influyeron directamente en las posibilidades de sobrevivir. Los pasajeros de primera clase tuvieron un acceso más sencillo a botes salvavidas, mientras que los de tercera clase enfrentaron restricciones físicas y sociales que limitaron sus oportunidades. Asimismo, el código de "mujeres y niños primero" se refleja en la mayor tasa de supervivencia femenina frente a la masculina.

Aunque la regla dictaba salvar primero a mujeres y niños, en la práctica hubo excepciones. Algunos hombres de primera clase sobrevivieron gracias a su influencia, mientras que

muchas mujeres y niños de tercera clase no lograron escapar. Esto muestra que, más allá del protocolo, factores como clase social, ubicación de los camarotes y acceso a la tripulación fueron decisivos.

Hipótesis de Investigación

Hipótesis #1: La posibilidad de supervivencia aumenta en cuestión de tener hijos menores a bordo

Justificación teórica: La posibilidad de supervivencia aumenta en cuestión de tener hijos menores a bordo, esto se puede considerar tomando en cuenta la regla moral que aumentaba considerablemente la posibilidad de supervivencia de los niños y los menores de edad. Tomando esto en cuenta, los padres pueden aprovechar esta regla para salvarse a sí mismos, usando a sus propios hijos como pase de entrada a los botes salvavidas.

Evidencia preliminar del EDA: En el punto 1.2.4 podemos ver una tabla que demuestra que el porcentaje de supervivencia de manera individual es del 34%, sin embargo, las familias con 1, 2 o 3 hijos aumentan en un 55, 50 y 60% respectivamente.

Variables involucradas: Tener hijos menores de edad a bordo del titanic, la posibilidad de supervivencia

- Variable dependiente: La posibilidad de supervivencia
- Variables independientes: La posibilidad de supervivencia
- Variables de control: El número de hijos menores de edad

Método de validación propuesto: Se pueden filtrar los datos por personas que tienen hijos y encontrar la posibilidad de supervivencia por persona, si la hipótesis es cierta entonces debería haber un aumento al resto de personas que no tenían familiares en el barco.

Implicaciones potenciales: A pesar de la evidencia, hay que tomar en cuenta la posibilidad de que muchas de estas personas tienen hijos que no son menores de edad, haciendo que los valores obtenidos sean menores del verdadero aumento de supervivencia.

Hipótesis #2: La probabilidad de supervivencia en primera clase es al menos 50% mejor que la de tercera clase, para todas las edades y géneros.

Justificación teórica: Considerando una dinámica y estilo de vida a bordo muy desigual a bordo del Titanic probablemente se tradujo en una preferencia o prioridad a los pasajeros de primera clase para abordar los botes, independientemente de otras variables como género o edad.

Evidencia preliminar del EDA: El análisis de porcentaje de supervivencia por género y clase.

Variables involucradas:

- Variable dependiente: Supervivencia (0 o 1).
- Variables independientes: clase del boleto (1era, 2nda, 3era).
- Variables de control: género.

Método de validación propuesto: Comparar supervivencia promedio por clases y género, dando valores entre 0 y 1. La hipótesis es válida si la diferencia en el valor de la supervivencia de tercera clase al de primera clase es igual o mayor a 0.5, para ambos géneros por separado.

Implicaciones potenciales: Esperamos una mejor tasa de supervivencia para las mujeres, pero si las mujeres *y los hombres* tienen mejor probabilidad de sobrevivir si son de primera clase, podemos inferir que algo sobre el estatus en el bote les dio una "ventaja".

Hipótesis #3: La posibilidad de supervivencia disminuye en cuestión de ser de tercera vinculados a varios familiares provenientes de Southampton

Justificación teórica: Tomando en consideración, el contexto histórico vinculado al incidente con el **RMS Titanic** y el concepto de las estratificaciones sociales, las mujeres y niños eran los pasajeros que tenían prioridad al momento de ingresar a los botes salvavidas, sin embargo, esta regla/disciplina no se cumplió debido a que existen tres ejemplos de clave Tickets vinculado a que la regla/disciplina previamente mencionada no se cumplia para las mujeres y niños de tercera clase con grandes cantidades de familiares (hermanos y padres) provenientes de Southampton, donde el **RMS Titanic** comenzó su viaje de inauguración.

Evidencia preliminar del EDA: Gráfico de Supervivencia por Subgrupo de Categorías de Tamaños de Familia

Variables involucradas:

- Variable dependiente: Supervivencia (0 a 1)
- Variables independientes: Tamaño Familia, OrigenClase3 y OrigenEmbarkedSouthampton
- Variables de control: Sexo, Edad y Ticket

Método de validación propuesto: Crear un subgrupo en donde se utilizan como punto de referencia las variables independientes para ir creando un dataframe que pueda abarcar diferentes rangos de tamaños de familia, después, el siguiente paso sería calcular la supervivencia de cada tamaño de familia y, por último, se podría agregar más criterios al subgrupo en base a las variables de control.

Implicaciones potenciales: Si se confirma que la supervivencia de los pasajeros de tercera clase con grandes familias y que se subieron al barco desde Southampton fue menor entonces ya estaban condicionados, de forma negativa, para sobrevivir y que la clase social no era el único valor importante para su supervivencia. Sin embargo, si la hipótesis es rechazada entonces se deben explorar otras variables de control para encontrar posibles correlaciones que funcionen mejor con el subgrupo o se podría modificar el subgrupo.

Hipótesis secundaria #1: En tercera clase sólo existía una opción de cuarto

Justificación teórica: A través de una contextualización histórica y cultural respecto a otros barcos y hoteles, inferimos que aquellos en primera y segunda clase serían ofrecidos habitaciones de diferente precio, capacidad, y lujo dentro de su misma clase, por lo que las tarifas no estarían correlacionadas fuertemente al número de gente en una familia, sino en cuáles habitaciones se hospedarían. En contraste, probablemente los de tercera clase no tenían tantas opciones de configuración de la habitación, y el precio de los boletos estaría fuertemente correlacionado al número de gente en la familia.

Evidencia preliminar del EDA: El análisis de porcentaje de supervivencia por género y clase.

Variables involucradas:

- Variable dependiente: Correlación al precio del boleto.
- Variables independientes: Número de familiares a bordo (1era, 2nda, 3era).
- Variables de control: Clase.

Método de validación propuesto: Agrupando por las diferentes clases, calcular la correlación entre tener muchos familiares a bordo con tu boleto, y el precio registrado en tu tarifa. Es decir, las columnas *FamilySize* y *Fare*.

Implicaciones potenciales: Si solo hay una fuerte correlación entre tarifa y familiares en la 3era clase, podemos asumir que las demás clases tienen más variables que afectan el precio de sus boletos. En el contexto de un barco de lujo haciendo viajes larguísimos, con un rango de precios enorme, podemos asumir que no solo había 3 tipos de habitaciones, sino que había habitaciones más o menos lujosas en las clases altas.

Conclusiones Preliminares

Resumen de insights

A través de los datos recibidos y las investigaciones realizadas se realizaron análisis sobre cada una de las variables que pudieron determinar la supervivencia de los pasajeros, incluyendo visualizaciones y tablas. Al mismo tiempo fue necesario mostrar los datos faltantes en el dataset para darles un trato diferente en caso de ser necesario.

Próximos pasos

Preguntas adicionales:

- ¿Había más diferencias entre las cabinas además de la clase?

 La hipótesis secundaria #1 plantea la imagen de que no pagan lo mismo por persona los pasajeros de primera y segunda clase, lo que sugiere que tenían opciones de habitaciones de diferentes precios y esa información no está en el dataset.
- ¿Cuál fue la tasa de supervivencia de la tripulación? ¿Qué la afectaba? Aunque sale del alcance de nuestro análisis y de el dataset, responder todas estas preguntas y analizar las circunstancias que afectaron las probabilidades de sobrevivir como pasajero nos hace también pensar en lo difícil que fue la situación para la tripulación. Aunque entendemos tradiciones marítimas como el capitán hundirse con su barco, ¿los oficiales tienen responsabilidades similares sobre su propia vida?

Referencias

Encyclopedia Titanica. (s. f.). *Social Class and Survival on the S.S. Titanic*. En *Encyclopedia Titanica*. Recuperado de

https://www.encyclopedia-titanica.org/social-class-and-survival-on-the-ss-titanic.html

Victorian-Era.org. (s. f.). Edwardian Era Society and daily life of the Edwardians. En Victorian-Era.org. Recuperado de https://victorian-era.org/edwardian-era-society.html

Lots of Essays. (s. f.). *The Titanic as a Microcosm of the Edwardian World*. En *LotsOfEssays.com*. Recuperado de https://www.lotsofessays.com/viewpaper/1686831.html

Amir. (2025, 3 de enero). *The Final Journey of RMS Titanic: A Cultural and Historical Analysis of the 1912 Disaster*. En *ArtifactsWS.art*. Recuperado de https://artifactsws.art/the-final-journey-of-rms-titanic-a-cultural-and-historical-analysis-of-the-1912-disaster/

Crudu, V. (2025, June 22). Data Scientist's Guide to Descriptive Statistics in R and Python. MoldStud - Custom Software Development Company.

https://moldstud.com/articles/p-data-scientists-guide-to-descriptive-statistics-in-r-and-python

Frey, B., Savage, A., & Torgler, B. (2011, March). Who perished on the Titanic? The importance of social norms. ResearchGate.

https://www.researchgate.net/publication/236131100_Who_perished_on_the_Titanic_The_im_portance_of_social_norms

GeeksforGeeks. (2025, July 15). Calculate the average, variance and standard deviation in Python using NumPy. GeeksforGeeks.

https://www.geeksforgeeks.org/data-science/calculate-the-average-variance-and-standard-deviation-in-python-using-numpy/

NUMPY - Descriptive Statistics. (n.d.).

https://www.tutorialspoint.com/numpy/numpy descriptive statistics.htm

Women and children first. (n.d.). National Army Museum.

https://www.nam.ac.uk/explore/birkenhead-sinking